

Panorama dos Dados Ambientais

Fontes, características e desafios para modelagem

Cesar de Oliveira F. Silva

Setembro / 2026

Roteiro

- 1 Introdução
- 2 Dados ambientais
- 3 Qualidade e problemas típicos
- 4 Integração e preparação


Por que falar de dados ambientais?

- Decisões em recursos hídricos, qualidade do ar, solos e ecossistemas dependem de **dados medidos** e **modelos calibrados**.
- A disponibilidade de sensores, redes automáticas e dados de satélite gera um **volume sem precedentes** de informação.
- Ao mesmo tempo, os dados ambientais são:
 - incompletos, ruidosos, inconsistentes e redundantes;
 - coletados em múltiplas escalas espaciais e temporais;
 - produzidos por diferentes instituições, com padrões variados.

Dados ambientais e ciência de dados

- Projetos de ciência de dados em ambiente tipicamente seguem um ciclo:
 - definição do problema e das variáveis de interesse;
 - coleta, integração e preparação de dados;
 - modelagem, validação e comunicação.
- Na prática, **a maior parte do esforço está na preparação de dados**:
 - em muitos cenários, limpeza, integração e transformação consomem $\approx 60\%$ ou mais do tempo total do projeto;
 - isso é especialmente verdadeiro para dados ambientais, pela heterogeneidade de fontes e formatos.

Pré-processamento de dados



Pré-processamento de dados

No mundo real, dados coletados e organizados tendem a ser:

- **Incompletos:** ausência de valores de atributos, ausência de atributos de interesse ou dados com valores agregados
- **Ruidosos:** existências de erros ou outliers
- **Inconsistentes:** unidades diferentes, formatos de data, convenções de nomes heterogêneas.
- **Redundantes:** registros duplicados, variáveis altamente correlacionadas.

Impacto

Esta fase pode consumir 75% ou mais do tempo de projeto.

Características descritivas de dados

No mundo real, dados coletados e organizados tendem a ser:

- **Medidas de posição e de dispersão dos dados:** média, max, min, quartis, outliers, variância, etc
- **Dimensões numéricas:** dispersão de dados é analisada em múltiplas granularidades, análise de Boxplot ou quartil em intervalos ordenados
- **Medidas de Assimetria:** (simetria e assimetria) Indicador da forma da distribuição dos dados.

Medidas de Posição (tendência central)

- **Média aritmética simples:** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ $\mu = \frac{\sum x}{N}$
- **Média aritmética ponderada:** $\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$
- **Moda (Mo):** é o valor mais frequente em um conjunto de valores numéricos.
- **Mediana (Md):** dado um grupo de dados ordenados, a mediana separa a metade inferior da amostra da metade superior.

Separatrizes

Não são medidas de tendência central. As separatrizes estão ligadas à mediana relativamente à sua característica de separar a série em duas partes que apresentam o mesmo número de valores.


As separatrizes são:

- **Quartil:** divide um conjunto de dados em quatro partes iguais.
- **Decil:** divide um conjunto de dados em dez partes iguais.
- **Percentil:** divide um conjunto de dados em cem partes iguais.




Exemplos de Separatrizes

Quartil: Os quartis dividem o conjunto de dados em quatro partes iguais:

- Se $(Md - Q1) = (Q3 - Md) \rightarrow$ **dist. simétrica.**
- Se $(Md - Q1) < (Q3 - Md) \rightarrow$ **assimetria à direita** ou **positiva**
- Se $(Md - Q1) > (Q3 - Md) \rightarrow$ **assimetria à esquerda** ou **negativa**




Distribuição Simétrica e Assimétrica




Medindo a dispersão dos dados

- **Quartils:** Q1 (25^o percentil), Q3 (75^o percentil).
- **Amplitude interquartílica:** $IQR = Q3 - Q1$ (50% dos dados).
- **Sumário dos 5 números:** Min, Q1, Med, Q3, Max.
- **Boxplot:** uma linha central mostrando a mediana, uma linha inferior mostrando o primeiro quartil, uma linha superior mostrando o terceiro quartil.
- **Outliers:** Limite Inferior = $Q1 - 1.5 \times IQR$; Limite Superior = $Q3 + 1.5 \times IQR$.




Análise de Boxplot

- Um **percentil** é uma medida da posição relativa de uma unidade observacional em relação a todas as outras.
- O **p-ésimo** percentil tem no mínimo **p% dos valores abaixo** daquele ponto e no máximo **(100 - p)% dos valores acima**.
- Se uma altura de 1,80m é o 90º percentil de uma turma de estudantes, então 90% da turma tem alturas menores que 1,80m e 10% tem altura superior a 1,80m.



Exemplo de Boxplots



Principais fontes de dados ambientais

- **Sensores in situ:** estações de monitoramento de qualidade da água, ar, clima, nível de rios etc.
- **Sensoriamento remoto:** satélites, drones, aeronaves (imagens multiespectrais, térmicas, radar).
- **Viagens de campo:** coletas de solo, vegetação, fauna, água subterrânea.
- **Modelos numéricos:** saídas de modelos hidrológicos, atmosféricos, oceânicos, de transporte de poluentes.
- **Dados administrativos e socioeconômicos:** uso e cobertura da terra, censos, cadastros de usuários de água.

Exemplos por domínio

Recursos hídricos

- Vazão, nível, precipitação.
- Qualidade da água (pH, turbidez, nutrientes).
- Operação de reservatórios.

Atmosfera

- $PM_{2.5}$, ozônio, NO_x , SO_2 .
- Variáveis meteorológicas (T, UR, vento).

Solos e vegetação

- Atributos físicos e químicos do solo.
- Cobertura vegetal, índices como NDVI.

Uso e ocupação

- Mapas de uso do solo.
- Infraestrutura urbana, estradas, barragens.

Dimensões dos dados ambientais

- **Temporal**

- Séries de minutos (sensores de qualidade da água) a séries anuais (clima, uso do solo).
- Sazonalidade, tendências de longo prazo, eventos extremos.

- **Espacial**

- Pontos (estações), linhas (rios), polígonos (bacias, municípios), grades (rasters).
- Variação em múltiplas escalas: local, regional, global.

- **Vertical / profundidade**

- Perfil de solos, colunas d'água, camadas atmosféricas.

Escalas e mudança de suporte

- Dados podem ser medidos em um **suporte** (escala de área/volume/tempo) e usados em outro.
- Exemplos:
 - Amostras pontuais de solo usadas para mapear classes em polígonos de uso do solo.
 - Imagens de satélite com pixel de 10 m agregadas para bacias de centenas de km².
- A **mudança de suporte** pode introduzir:
 - suavização de extremos (perda de variabilidade local);
 - viés em estimativas de médias ou totais;
 - inconsistência entre camadas em diferentes resoluções.

Problemas típicos de qualidade de dados

- **Incompletos:** valores faltantes, períodos sem medição, atributos não observados.
- **Ruidosos:** leituras afetadas por falhas de sensores, transmissão, calibração.
- **Inconsistentes:** unidades diferentes, formatos de data, convenções de nomes heterogêneas.
- **Redundantes:** registros duplicados, variáveis altamente correlacionadas.

Impacto

Sem qualidade de dados, não há qualidade nos resultados: erros em decisões de gestão, estimativas enviesadas, modelos com baixa capacidade de generalização.

Valores faltantes e censura

- **Valores faltantes** surgem por:
 - falhas de equipamentos;
 - problemas de comunicação;
 - dados não coletados ou descartados;
 - mudanças no protocolo de amostragem.
- Em muitos casos ambientais, há ainda **censura**:
 - valores abaixo do limite de detecção ($< \text{LOD}$);
 - registros reportados como intervalos (10–20 mg/L).
- A forma de tratar faltantes/censura precisa ser consistente com:
 - o fenômeno físico;
 - o método estatístico ou de aprendizado a ser usado.

Ruído, outliers e redundância

- **Ruído:**
 - perturbação aleatória ou sistemática dos valores;
 - pode ser atenuado por filtros, modelos de regressão, janelas móveis.
- **Outliers:**
 - podem indicar erro de medição *ou* eventos extremos reais;
 - requerem análise cuidadosa (boxplots, clusterização, inspeção de séries).
- **Redundância:**
 - variáveis muito correlacionadas ou derivadas (por exemplo, concentração e carga);
 - pode ser avaliada por correlação de Pearson, qui-quadrado para categóricas, VIF etc.

Eliminação de inconsistências

Mesmo valor de um atributo para diferentes rótulos: O mesmo dado é representado por rótulos diferentes.

ATRIBUTOS					CLASSE
Dia	Tempo	Temperatura	Umidade	Vento	Joga-Tenis
1	Sol	Quente	Alta	Fraco	Não
2	Sol	Quente	Alta	Forte	Não
3	Nublado	Quente	Alta	Fraco	Sim
4	Chuva	Moderado	Alta	Fraco	Sim
5	Chuva	Frio	Normal	Forte	Sim
6	Chuva	Frio	Normal	Forte	Não
7	Nublado	Frio	Normal	Forte	Sim
8	Sol	Moderado	Alta	Fraco	Não
9	Sol	Frio	Normal	Fraco	Sim

Correlação não implica causalidade




Vendas de sorvete e ataques de tubarão aumentam no verão.

Apesar da correlação, uma NÃO CAUSA a outra

Integração de dados ambientais

Processo que combina dados residentes em diferentes fontes, mantendo a consistência e a coerência dos dados integrados.



Integração de dados ambientais

- Combinar dados de diferentes fontes é essencial:
 - integrar bancos de solos, clima, hidrologia, uso do solo, socioeconomia;
 - juntar séries temporais, rasters e vetores em um mesmo fluxo analítico.
- Desafios:
 - diferentes sistemas de georreferenciamento (CRS), resoluções espaciais e temporais;
 - esquemas de atributos incompatíveis (nomes, categorias, unidades);
 - conflitos e duplicações na integração.

Preparação de dados como etapa crítica

- Limpeza e integração de dados:
 - identificação e tratamento de faltantes, ruídos, inconsistências;
 - padronização de unidades, formatos e categorias;
 - reamostragem temporal e espacial coerente com a física do problema.
- Exploração descritiva:
 - medidas de posição (média, mediana), dispersão (desvio padrão, IQR);
 - histogramas, boxplots, matrizes de correlação.
- Essa etapa:
 - melhora a precisão dos modelos;
 - reduz retrabalho e interpretações equivocadas;
 - aumenta a confiança nas decisões posteriores.

Resumo e mensagem central

- Dados ambientais são intrinsecamente:
 - espaço-temporais, heterogêneos e incertos;
 - sujeitos a erros, faltantes e inconsistências.
- Entender esse panorama é condição prévia para:
 - projetar fluxos de preparação de dados realistas;
 - escolher modelos e métodos adequados;
 - interpretar resultados com consciência das limitações.
- Em síntese:

A qualidade das decisões ambientais é limitada pela qualidade dos dados e do seu pré-processamento.