

IA para Engenharia Ambiental

Python e Ecosystema Científico

Cesar de Oliveira F. Silva

Setembro / 2026

Roteiro

- 1 Por que Python para ML?
- 2 Fundamentos de Python
- 3 Arquivos, coleções e bibliotecas
- 4 NumPy, Pandas, Matplotlib, Scikit-Learn
- 5 Exemplo de pipeline em ML

Programação para ML: visão geral

- Aprendizado de Máquina é como um **laboratório virtual**: fazemos experiências com dados.
- Python é o **idioma** que usamos para conversar com esse laboratório.
- Objetivos da aula:
 - Entender o básico de Python como linguagem.
 - Ver estruturas fundamentais: variáveis, decisões, repetições, funções.
 - Conhecer bibliotecas centrais: **NumPy, Pandas, Matplotlib, Scikit-Learn**.

Por que Python?

- Sintaxe simples e próxima de pseudocódigo.
- Grande ecossistema científico:
 - **NumPy**: vetores e matrizes.
 - **Pandas**: tabelas de dados.
 - **Matplotlib**: gráficos.
 - **Scikit-Learn**: algoritmos de ML.
- Comunidade enorme e muitos exemplos prontos.
- Metáfora: Python é um **canivete suíço** para ciência de dados.

Ambientes de trabalho em Python

- **Interpretador** (terminal): bom para testes rápidos.
- **Notebooks Jupyter**: misturam texto, fórmulas, código e gráficos.
 - Ótimos para relatórios e experimentos em ML.
- **IDE** (VSCode, PyCharm, Spyder): edição de projetos maiores.
- Ideia: pense no notebook como um **caderno de laboratório digital**.

Variáveis: caixinhas com rótulo

Variável = **caixa na memória** com um nome (rótulo) e um valor dentro.

Exemplo:

```
1 idade = 21           # inteiro (int)
2 temp = 28.5          # ponto flutuante (float)
3 nome = "Ana"         # texto (str)
4 chovendo = True      # booleano (bool)
```

- Python descobre o tipo automaticamente (*tipagem dinâmica*).
- Metáfora: mudar o valor da variável é como trocar o conteúdo da caixa mantendo o mesmo rótulo.

Conversões e operações básicas

- Operadores: $+$, $-$, $\times$, $\div$, potência ($**$), módulo ($\%$).
- Conversões: `int()`, `float()`, `str()`.
- Atenção: `"10" + "5"` concatena texto, não soma.

Decisões: if, elif, else

- Estruturas de decisão são como um **cruzamento** na estrada: o código escolhe qual caminho seguir.

```
1 temp = 30
2 if temp > 30:
3     print("Muito quente")
4 elif temp >= 20:
5     print("Clima agradável")
6 else:
7     print("Frio")
8
```

- Condições lógicas: >, <, >=, <=, ==, !=.

Repetições: fazendo o computador repetir por você

Laços são como dizer: **“faça isso para cada elemento da lista”** ou **“repita enquanto esta condição for verdadeira”**.
for sobre uma coleção

```
1 nomes = ["Ana", "Bruno", "Carla"]  
2  
3 for n in nomes:  
4     print("Olá, ", n)  
5
```

while com condição

```
1 contador = 0  
2  
3 while contador < 3:  
4     print(contador)  
5     contador = contador + 1  
6
```

Funções: receitas reutilizáveis

- Função = **receita de bolo**: recebe ingredientes (parâmetros), segue passos e devolve um resultado.

```
1 def soma(a, b):  
2     """Devolve a soma de a e b."""  
3     resultado = a + b  
4     return resultado  
5  
6 x = soma(3, 4)    # x = 7  
7
```

- Vantagens: organização, reutilização, evita copiar e colar código.

Coleções em Python

- **Lista** (`list`): sequência mutável, ordenada.
- **Tupla** (`tuple`): sequência imutável.
- **Dicionário** (`dict`): mapeamento chave → valor.
- **Conjunto** (`set`): coleção sem ordem, sem repetição.

```
1 lista = [10, 20, 30]
2 tupla = (1.0, 2.0)
3 d = {"rio": "Tietê", "estado": "SP"}
4 conj = {1, 2, 2, 3}      # {1, 2, 3}
5
```

- Metáfora: listas e tuplas são **filas de caixas**; dicionários são **gavetas com etiquetas**.

Leitura e escrita de arquivos

- Precisamos ler dados de arquivos (ex.: CSVs de qualidade da água).
- Estrutura básica:

```
1 # Leitura linha a linha
2 with open("dados.txt", "r", encoding="utf-8") as f:
3     for linha in f:
4         print(linha.strip())
5
6 # Escrita
7 with open("saida.txt", "w", encoding="utf-8") as f:
8     f.write("Resultado do modelo: 0.87\n")
9
```

- `with` garante que o arquivo será fechado corretamente.

Bibliotecas: caixas de ferramentas prontas

- Biblioteca = conjunto de funções e classes já implementadas.
- Importando bibliotecas:

```
1 import math
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5
```

- Metáfora: em vez de construir o martelo, você **importa** o conjunto de ferramentas.

NumPy: vetores e matrizes eficientes

- NumPy = motor numérico do Python científico.
- **Array NumPy** é como uma planilha só de números, muito rápida.

```
1 import numpy as np
2
3 a = np.array([1, 2, 3])
4 b = np.array([10, 20, 30])
5
6 soma = a + b           # [11 22 33]
7 media = a.mean()      # 2.0
8 mat = np.array([[1, 2],
9                 [3, 4]])
10 det = np.linalg.det(mat)
11
```

- Operações são **vetorizadas**: aplicadas a todos os elementos de uma vez.

Pandas: tabelas de dados (DataFrames)

- Pandas oferece o **DataFrame**: tabela com linhas e colunas nomeadas.
- Ideal para dados ambientais (estações, datas, variáveis).

```
1 import pandas as pd
2
3 df = pd.read_csv("qualidade_agua.csv")
4 print(df.head())           # primeiras linhas
5 print(df.columns)          # nomes das colunas
6
7 # Filtrar e calcular
8 df_sp = df[df["estado"] == "SP"]
9 media_ph = df_sp["pH"].mean()
10
```

Matplotlib: visualização de dados

- Matplotlib = **prancheta de desenho** para gráficos.

```
1 import matplotlib.pyplot as plt
2
3 plt.figure()
4 plt.plot(df["data"], df["OD"], label="Oxigênio dissolvido")
5 plt.xlabel("Data")
6 plt.ylabel("OD (mg/L) ")
7 plt.title("Série temporal de OD")
8 plt.legend()
9 plt.show()
10
```

- Gráficos ajudam a enxergar padrões, outliers e tendências.

Scikit-Learn: algoritmos de ML em poucas linhas

- Biblioteca padrão de ML em Python.
- Metáfora: cada modelo é um **aparelho** que você pluga nos seus dados.

```
1 from sklearn.model_selection import train_test_split
2 from sklearn.linear_model import LinearRegression
3
4 X = df[["chuva", "temperatura"]] # atributos
5 y = df["vazao"]                 # alvo
6
7 X_train, X_test, y_train, y_test = \
8     train_test_split(X, y, test_size=0.2,
9                     random_state=42)
10
11 modelo = LinearRegression()
12 modelo.fit(X_train, y_train)     # treinar
13 pred = modelo.predict(X_test)   # prever
14
```

Padrão de uso no Scikit-Learn

- 1 Escolher um modelo (`LinearRegression`, `RandomForest`, `SVC`, ...).
- 2 Criar o objeto do modelo.
- 3 Chamar `fit(X_train, y_train)` para treinar.
- 4 Chamar `predict(X_test)` para obter previsões.
- 5 Avaliar o desempenho com métricas (RMSE, acurácia, etc.).

Ideia central

Programar para ML é construir esse fluxo:

dados → **pré-processamento** → **modelo** → **avaliação**.

Mini-exemplo de pipeline em ML

```
1 import pandas as pd
2 from sklearn.model_selection import train_test_split
3 from sklearn.ensemble import RandomForestRegressor
4 from sklearn.metrics import mean_squared_error
5
6 # 1. Ler dados
7 df = pd.read_csv("qualidade_agua.csv")
8
9 # 2. Escolher atributos e alvo
10 X = df[["chuva", "temperatura", "OD"]]
11 y = df["vazao"]
12
13 # 3. Separar treino e teste
14 X_train, X_test, y_train, y_test = \
15     train_test_split(X, y, test_size=0.2, random_state=0)
16
17 # 4. Criar e treinar modelo
18 rf = RandomForestRegressor(n_estimators=100, random_state=0)
19 rf.fit(X_train, y_train)
20
21 # 5. Avaliar
22 y_pred = rf.predict(X_test)
23 rmse = mean_squared_error(y_test, y_pred, squared=False)
24 print("RMSE =", rmse)
25
```

Resumo

- Vimos Python como **linguagem base** para ML.
- Exploramos:
 - Variáveis, decisões, laços e funções.
 - Leitura de arquivos e coleções.
 - Bibliotecas centrais: NumPy, Pandas, Matplotlib, Scikit-Learn.
- Próximos passos:
 - Praticar com pequenos scripts.
 - Reproduzir o mini-pipeline com seus próprios dados ambientais.
 - Preparar o terreno para **Redes Neurais Artificiais**.