


Aprendizado de representações latentes

Cesar de Oliveira F. Silva

Setembro / 2026

Representações latentes e dimensionalidade



Ideia central

Muitos dados ambientais de alta dimensão podem ser descritos por um número menor de fatores latentes. O objetivo é aprender uma representação compacta, informativa e útil para compressão, análise, detecção de anomalias e modelagem downstream.

Por que reduzir dimensionalidade?

- Em muitos problemas ambientais, os dados observados vivem em espaço de alta dimensão:
 - rasters multibanda;
 - cubos hiperespectrais;
 - séries multivariadas;
 - campos espaço-temporais massivos.
- No entanto, a estrutura efetiva dos dados pode ser muito mais simples.

Objetivo

Mapear

$$x \in \mathbb{R}^D \longrightarrow z \in \mathbb{R}^d, \quad d \ll D$$

preservando a informação essencial.

Representações latentes: intuição geométrica

- Hipótese do *manifold*: dados complexos ocupam subespaços de menor dimensão.
- A representação latente busca capturar essa estrutura intrínseca.
- Em termos práticos, o espaço latente organiza:
 - similaridade espectral;
 - regimes hidrológicos;
 - padrões sazonais;
 - dinâmicas espaço-temporais recorrentes.

Interpretação

Pontos próximos no espaço latente tendem a corresponder a amostras com comportamento semelhante no domínio original.

Autoencoders (AE): arquitetura básica

Estrutura

$$z = f_{\theta}(x), \quad \hat{x} = g_{\phi}(z)$$

- O **encoder** comprime a entrada em uma representação latente.
- O **decoder** reconstrói a entrada a partir dessa representação.
- O gargalo (*bottleneck*) força a rede a reter apenas os fatores mais relevantes.

Treinamento

$$\mathcal{L}_{rec} = \|x - \hat{x}\|^2$$

ou variantes baseadas em MAE, SSIM ou perdas perceptuais.

O que o autoencoder aprende?

- Um autoencoder não supervisionado tenta reconstruir a entrada com o menor erro possível.
- Para isso, ele precisa aprender regularidades, redundâncias e fatores dominantes nos dados.
- O espaço latente pode então ser usado como:
 - compressão não linear;
 - extrator de atributos;
 - base para clusterização;
 - representação para modelos supervisionados.

Mensagem prática

O valor do AE não está apenas na reconstrução, mas na utilidade da representação intermediária z .

Variantes de autoencoders

- **Denoising Autoencoder:**
 - recebe entrada corrompida;
 - aprende reconstrução limpa;
 - aumenta robustez a ruído.
- **Sparse Autoencoder:**
 - penaliza ativações latentes;
 - favorece representações mais parsimoniosas.
- **Convolutional Autoencoder:**
 - adequado para imagens e rasters.
- **Sequence Autoencoder:**
 - usa RNNs, TCNs ou Transformers;
 - adequado para séries temporais.

Autoencoders variacionais (VAE)

- O VAE introduz uma interpretação probabilística para o espaço latente.
- Em vez de mapear cada entrada para um ponto fixo, aprende-se uma distribuição latente:

$$q_{\phi}(z|x)$$

- O decoder modela a reconstrução por:

$$p_{\theta}(x|z)$$

Ideia principal

O espaço latente deixa de ser apenas compacto e passa a ser também **regularizado** e **amostravel**.

Função objetivo do VAE

ELBO

$$\mathcal{L} = \mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{KL}(q(z|x) \| p(z))$$

- Primeiro termo: qualidade de reconstrução.
- Segundo termo: aproxima a distribuição latente de um prior, tipicamente

$$p(z) = \mathcal{N}(0, I)$$

Consequência

O VAE favorece um espaço latente contínuo, suave e mais apropriado para geração, interpolação e análise probabilística.

Construção do espaço latente

- A dimensão de z controla o compromisso entre:
 - **compressão;**
 - **fidelidade de reconstrução;**
 - **interpretabilidade.**
- Regularizações adicionais podem impor mais estrutura ao latente.

Exemplos

- β -**VAE**: reforça separação entre fatores latentes;
- penalizações de suavidade, esparsidade ou independência;
- restrições guiadas por estrutura espacial ou temporal.

Visualização e exploração do espaço latente

- Mesmo quando z tem dimensão moderada, é útil inspecioná-lo por projeções adicionais.
- Ferramentas comuns:
 - PCA;
 - t-SNE;
 - UMAP.
- Objetivos:
 - identificar clusters;
 - detectar regimes;
 - explorar transições entre estados;
 - avaliar separabilidade de padrões ambientais.

Exemplo

Agrupamentos no latente podem refletir estações do ano, tipos de cobertura, regimes hidrológicos ou eventos extremos.

Aprendizado não supervisionado em dados ambientais

- Em muitos cenários, há poucos rótulos e muitos dados brutos.
- Isso torna representações latentes especialmente úteis.
- Estratégias complementares:
 - autoencoders;
 - reconstrução mascarada;
 - contrastive learning;
 - pré-treinamento auto-supervisionado.

Fluxo típico

pré-treinamento do encoder → extração de features → fine-tuning para tarefa supervisionada

Compressão de dados ambientais de alta dimensionalidade

- Aplicações típicas:
 - compressão de rasters multibanda;
 - cubos hiperespectrais;
 - grades climáticas 4D;
 - sequências espaço-temporais extensas.
- Benefícios:
 - redução de armazenamento;
 - menor custo de transmissão;
 - inferência mais eficiente;
 - representação compacta para indexação e busca.

Comparação com PCA

PCA captura estrutura linear; autoencoders capturam relações não lineares e interações mais complexas.

Detecção de anomalias por reconstrução

- Se o modelo é treinado principalmente em padrões normais, eventos raros tendem a ser mal reconstruídos.
- Isso permite usar o erro de reconstrução como indicador de anomalia.

Métrica básica

$$s(x) = \|x - \hat{x}\|$$

- Em modelos probabilísticos, também é possível usar:
 - probabilidade latente;
 - score de energia;
 - densidade aproximada sob o modelo.

Anomalias e eventos extremos em aplicações ambientais

- Eventos potencialmente detectáveis:
 - blooms algais;
 - picos de turbidez;
 - cheias e secas anômalas;
 - mudanças abruptas de cobertura da terra;
 - falhas de sensor ou artefatos de medição.
- O espaço latente pode complementar o erro de reconstrução:
 - clusterização de regimes normais;
 - distância à distribuição histórica;
 - monitoramento de trajetórias latentes ao longo do tempo.

Monitoramento contínuo no espaço latente

- Em dados temporais, podemos observar a trajetória z_t ao longo do tempo.
- Mudanças de regime podem aparecer como deslocamentos persistentes no espaço latente.
- Isso é útil para:
 - *early warning*;
 - detecção de drift;
 - identificação de transições sazonais;
 - acompanhamento de extremos emergentes.

Ideia prática

Não observar apenas o erro instantâneo, mas também a dinâmica histórica da representação latente.

Masked autoencoders e pré-treinamento

- Parte da entrada é mascarada e o modelo aprende a reconstruí-la.
- Isso força o encoder a capturar estrutura contextual dos dados.
- Em dados ambientais, é promissor para:
 - rasters multibanda;
 - séries espaço-temporais;
 - pré-treinamento em grandes acervos sem rótulos.

Integração espaço-temporal

- Para dados ambientais, a estrutura raramente é apenas espacial ou apenas temporal.
- Arquiteturas híbridas são comuns:
 - encoder convolucional para padrões espaciais;
 - módulo temporal com RNN, TCN ou Transformer;
 - embedding global que resume a dinâmica espaço-temporal.
- Aplicações:
 - compressão de reanálises multi-decadais;
 - monitoramento climático;
 - detecção de mudanças locais persistentes.

Avaliação e validação

- **Reconstrução:**

- MSE;
- MAE;
- SSIM para imagens.

- **Anomalias:**

- AUC-ROC;
- precision-recall;
- métricas sensíveis a eventos raros.

- **Validação:**

- temporal;
- espacial;
- por domínio ou região.

Cuidado

Em dados ambientais, leakage espacial e temporal pode inflar artificialmente a qualidade da representação.

Limitações e cuidados

- Autoencoders podem reconstruir bem anomalias frequentes ou parecidas com o treino.
- Espaços latentes não são automaticamente interpretáveis em termos físicos.
- Variáveis heterogêneas exigem:
 - normalização consistente;
 - tratamento de escalas distintas;
 - cuidado com faltantes e ruído instrumental.
- Alta qualidade de reconstrução não garante utilidade para tarefas downstream.

Aplicações práticas ambientais

- Compressão de dados satelitais antes de armazenamento ou transmissão.
- Identificação de regimes hidrológicos distintos.
- Redução de dimensionalidade para visualização de padrões climáticos.
- Detecção de mudanças estruturais em séries de longo prazo.
- Extração de features para classificação, segmentação e previsão.

Resumo estratégico

- 1 Use AE para compressão não linear e extração de representações úteis.
- 2 Use VAE quando precisar de estrutura probabilística no espaço latente.
- 3 Para anomalias, combine erro de reconstrução com análise estatística no latente.
- 4 Em dados ambientais, trate explicitamente espaço, tempo e heterogeneidade de variáveis.
- 5 Sempre valide de forma temporal e espacial.