

Deep Learning e Sustentabilidade

Cesar de Oliveira F. Silva

Setembro / 2026

Deep Learning e sustentabilidade — o paradoxo

- IA pode apoiar mitigação e adaptação climática:
 - previsão de eventos extremos;
 - monitoramento ambiental;
 - otimização de recursos naturais.
- Porém, modelos modernos exigem grande poder computacional.

Paradoxo

Usar modelos intensivos em energia para resolver problemas ambientais.

- Isso exige avaliar não apenas desempenho, mas também **custo ambiental da computação**.

De onde vem o custo energético?

- Treinamento envolve:
 - milhões de iterações;
 - operações matriciais intensivas;
 - uso contínuo de GPUs/TPUs.
- O consumo total depende de:
 - tamanho do modelo;
 - número de parâmetros;
 - duração do treino;
 - número de experimentos realizados.

Observação

Busca de hiperparâmetros pode multiplicar o custo total de forma significativa.

Infraestrutura e intensidade de carbono

- Data centers diferem em eficiência energética:
 - métrica típica: PUE (Power Usage Effectiveness);
 - eficiência de resfriamento e distribuição elétrica.
- A pegada de carbono depende da matriz energética local:
 - energia renovável vs fóssil;
 - localização geográfica do cluster.

Implicação prática

A mesma carga computacional pode ter impactos ambientais muito diferentes dependendo de onde é executada.

Pegada de carbono em Deep Learning

- Emissões associadas ao treinamento dependem de:
 - consumo energético total;
 - intensidade de carbono da energia utilizada.
- Treinamentos repetidos amplificam o impacto:
 - tuning de hiperparâmetros;
 - múltiplas seeds;
 - experimentação exploratória.

Boa prática

Estimular a medição e o reporte de energia e emissões em experimentos.

Eficiência como critério científico

- Avaliação não deve considerar apenas acurácia.
- Também é relevante medir:
 - custo computacional;
 - consumo energético;
 - eficiência por ganho de desempenho.

Exemplos de métricas

FLOPs, energia por epoch, ganho marginal por unidade de energia.

Princípio

Melhor modelo nem sempre é o mais preciso, mas o mais eficiente para o contexto.

Estratégias para reduzir impacto

- Evitar treinamento do zero sempre que possível:
 - transfer learning;
 - modelos pré-treinados.
- Reduzir tamanho e custo do modelo:
 - pruning;
 - quantização;
 - distillation.
- Melhorar eficiência do treinamento:
 - early stopping;
 - busca eficiente de hiperparâmetros;
 - escolha adequada de arquitetura.

Do desempenho técnico à responsabilidade

- Modelos ambientais frequentemente suportam decisões críticas:
 - alertas de risco;
 - planejamento urbano;
 - gestão de recursos hídricos.
- Erros podem afetar diretamente populações vulneráveis.

Implicação

Avaliar modelos apenas por métricas técnicas é insuficiente.

Transparência e explicabilidade

- Técnicas comuns:
 - SHAP, LIME;
 - Grad-CAM;
 - mapas de atenção.
- Objetivo:
 - entender fatores que influenciam previsões;
 - apoiar auditoria e validação;
 - aumentar confiança institucional.

Uso prático

Identificar dependências plausíveis e detectar padrões espúrios.

Limitações da explicabilidade

- Explicações são frequentemente aproximações locais.
- Atenção e importância não implicam causalidade.
- Métodos diferentes podem produzir explicações distintas.

Risco

Falsa sensação de entendimento pode levar a decisões excessivamente confiantes.

IA, equidade e justiça ambiental

- Dados ambientais não são distribuídos de forma homogênea.
- Regiões com mais infraestrutura geram mais dados e melhores modelos.

Riscos

- sub-representação de comunidades vulneráveis;
 - viés geográfico;
 - decisões desiguais baseadas em dados incompletos.
-
- Necessidade de validação em múltiplos contextos e regiões.

Governança e boas práticas

- Documentação de dados:
 - *datasheets for datasets*;
 - descrição de origem, limitações e viés.
- Documentação de modelos:
 - *model cards*;
 - contexto de uso e restrições.
- Auditoria:
 - revisão independente;
 - rastreabilidade de decisões.

Trade-offs estratégicos

- Ganhos marginais de desempenho podem não justificar alto custo energético.
- Modelos menores ou híbridos podem ser mais sustentáveis.
- A decisão deve considerar:
 - impacto social da aplicação;
 - custo computacional;
 - robustez e interpretabilidade.

Exemplo

Melhoria de 1% em acurácia pode não justificar aumento significativo de consumo energético.

Futuro sustentável do Deep Learning

- **Green AI:**

- foco em eficiência e transparência;
- métricas além da acurácia.

- **Infraestrutura:**

- uso crescente de energia renovável;
- otimização de data centers.

- **Pesquisa:**

- modelos mais eficientes;
- benchmarks que incluam custo ambiental.

IA para decisão ambiental

- O objetivo final não é prever, mas apoiar decisão.
- Exemplos:
 - emitir alerta;
 - alocar recursos;
 - mitigar risco.

Insight

Modelo mais útil é aquele que melhora decisões, não apenas métricas.

Custo vs benefício em Deep Learning

- Nem todo ganho de performance justifica aumento de custo.

Pergunta central

Qual é o ganho marginal por unidade de energia ou custo computacional?

- Avaliar:
 - ganho em métricas;
 - impacto operacional;
 - custo ambiental.

Resumo estratégico

- 1 Avaliar modelos considerando desempenho e custo energético.
- 2 Reduzir impacto com técnicas de eficiência e reuso.
- 3 Garantir transparência, explicabilidade e documentação.
- 4 Considerar equidade e justiça ambiental nas aplicações.
- 5 Priorizar impacto social positivo frente ao custo computacional.